

SkillBench

调研

Operations领域调研

Operations领域，通常称为运营管理，是管理学的核心分支之一，它专注于设计、管理和优化组织用于生产与交付产品或服务的流程与系统。其核心目标是确保组织能够高效、高质地满足客户需求。

核心价值与重要性

运营管理是企业竞争力的基石。它直接关系到产品的成本、质量、交付速度和灵活性。卓越的运营能力帮助企业降低成本、提升客户满意度，并构建难以模仿的竞争优势。

主要关注内容

该领域主要围绕“投入-转化-产出”这一核心链条展开：

1. **流程设计与优化**：分析和设计业务流程，如生产线布局、服务蓝图，以消除浪费、提升效率。
2. **供应链管理**：管理从原材料采购到产品交付给最终用户的整个网络，包括物流、库存和供应商关系。
3. **质量管理**：确保产品和服务符合标准，涉及质量控制、质量保证和持续改进方法（如六西格玛）。
4. **产能与需求规划**：平衡生产能力与市场需求，涉及预测、排程和资源分配。
5. **项目管理**：规划、执行与控制特定的运营项目，确保在范围、时间和预算内达成目标。

Operations 领域的技能

1. **供应链 (Supply Chain)**
 - 库存管理策略 (EOQ、ROP)
 - 需求预测 (时间序列预测、机器学习预测)
 - 运输与物流优化
 - 库存补货计划生成
2. **排程优化 (Scheduling / Optimization)**
 - Job Shop Scheduling 问题求解
 - 流水线优化
 - 生产计划调度 (Heuristic / Metaheuristic)
 - 资源分配和负载均衡
3. **质量管理 (Quality Management)**

- SPC (Statistical Process Control) 分析
- 缺陷检测 (规则/机器学习)
- 六西格玛分析
- 过程能力指数 (Cp, Cpk) 计算

4. 流程分析 (Process Analysis)

- 流程瓶颈识别
- 流程仿真与优化
- KPI/流程效率分析
- Event Log Process Mining 技能

SkillsBench工作调研

基于Harbor测试框架

Harbor 是一个针对 **AI Agent / LLM Agent** 的测评平台，它的核心功能是：

- 对 Agent 的 **技能能力 (Skills)**、**任务完成情况**、**交互效果**进行自动化测评
- 支持 **自定义场景/任务**，可以生成结构化测评报告
- 可以接入 **多种 LLM/Agent**

特点：

- **模块化**：可以拆分技能测试 (Skill Eval)、任务测试 (Task Eval)、用户交互测试
- **自动评分**：结合规则和模型评估，生成评分和对比
- **数据驱动**：可以用现成数据集或自定义数据集做测评

分析了SkillsBench部分任务，基本都是有确定性结果。

无 Skills、专家人工构建的 Skills、AI 自生成的 Skills

AI自动生成skill task是增加了这段prompt：


Important: Generate Skills First

Before attempting to solve this task, please follow these steps:

1. **Analyze the task requirements** and identify what domain knowledge, APIs, or techniques are needed.
2. **Write 1-5 modular skill documents** that would help solve this task. Each skill should:
 - Focus on a specific tool, library, API, or technique
 - Include installation/setup instructions if applicable
 - Provide code examples and usage patterns
 - Be reusable for similar tasks
3. **Save each skill** as a markdown file in the `environment/skills/` directory with a descriptive name (e.g., `pandas-dataframe.md`, `opencv-image-processing.md`).
4. **Then solve the task** using the skills you created as reference.

This approach tests your ability to identify and document relevant knowledge before applying it.

有无skill控制机制：每个task的Dockerfile文件



后续可以通过这个框架进行测试

核心任务是充分了解operation领域，定义代表性任务，找到/创建合适skill+数据集

Operation领域skill

供应链与经济分析 (Supply Chain & Economic Analysis)

Task: shock-analysis-supply (供给侧冲击分析)

- 路径: `tasks/shock-analysis-supply/`
- Skills: `xlsx`
- 用途: 使用 Cobb-Douglas 生产函数估计小型开放经济体的投资支出冲击，涉及 GDP 预测、资本存量计算、HP 滤波等

Task: shock-analysis-demand (需求侧冲击分析)

- 路径: `tasks/shock-analysis-demand/`
- Skills: `xlsx`
- 用途: 需求侧经济冲击分析

Task: econ-detrending-correlation (经济时间序列去趋势)

- 路径: `tasks/econ-detrending-correlation/environment/skills/`
- Skills:
 - `timeseries-detrending` - 时间序列去趋势分析
- 用途: 宏观经济时间序列分解为趋势和周期成分, 包含 HP 滤波 (Hodrick-Prescott Filter) 实现、对数变换、商业周期相关性分析
-

制造与生产运营 (Manufacturing Operations)

Task: manufacturing-equipment-maintenance

- 路径: `tasks/manufacturing-equipment-maintenance/environment/skills/`
- Skills:
 - `reflow-profile-compliance-toolkit` - 回流焊设备合规性检测工具包
 - `reflow_machine_maintenance_guidance` - 回流焊设备维护指南
- 用途: 自动化工程师使用手册指导进行回流焊设备维护, 包括温度曲线计算 (预热升温速率、液相以上时间 TAL、峰值温度)、传送带速度可行性分析等

Task: manufacturing-fjsp-optimization (柔性作业车间调度)

- 路径: `tasks/manufacturing-fjsp-optimization/environment/skills/`
- Skills:
 - `fjsp-baseline-repair-with-downtime-and-policy` - 柔性作业车间调度修复技能
- 用途: 修复不可行或非最优的生产调度方案, 考虑机器停机窗口、工序优先级、策略预算约束, 最小化完工时间 (makespan)

Task: manufacturing-codebook-normalization

- 路径: `tasks/manufacturing-codebook-normalization/environment/skills/`
- Skills:
 - `manufacturing-failure-reason-codebook-normalization` - 制造失效原因代码标准化
- 用途: 将测试工程师编写的不规范缺陷原因标准化, 匹配产品代码本, 处理拼写错误、缩写误用、模糊描述等问题

初步尝试-基于harbor

目前初步制定任务：

1. 库存控制和补货
2. 供应商风险和升级管理
3. 瓶颈恢复和短期产能规划

= = harbor环境配置坑太多了，费时较久，暂时搁置，先手动测试吧

自行构造测试框架

数据集：

DataCo SMART SUPPLY CHAIN FOR BIG DATA ANALYSIS

<https://data.mendeley.com/datasets/8gx2fvg2k6/5>

冒烟任务：Online Retail Replenishment Review

任务介绍

零售补货计划任务。

它模拟的是：一个小型线上零售商要做每日补货复盘，agent 需要根据真实交易数据派生出的 SKU 需求历史、当前库存和库存政策，生成一份可执行的补货建议表，以及一份高风险缺货异常清单。

任务文件在这里：

- 任务说明：[instruction.md](#)
- 输入数据：[environment/data](#)
- oracle 解法：[solve.sh](#)
- 测试文件：[test_outputs.py](#)
- 外部 skill：[supply-chain-manager](#)

任务输入

它读取三个文件：

/app/data/daily_sku_demand.csv

/app/data/current_inventory.csv

/app/data/inventory_policy.csv

含义分别是：

- `daily_sku_demand.csv`: 每个 SKU 每天卖了多少件, 来自 Online Retail II 的真实交易数据派生。
- `current_inventory.csv`: 每个 SKU 当前还有多少库存。
- `inventory_policy.csv`: 每个 SKU 的补货政策, 比如提前期、安全库存、包装规格、最小起订量、高优先级阈值。

任务输出

它要生成两个文件:

`/app/output/replenishment_plan.csv`

`/app/output/replenishment_exceptions.json`

`replenishment_plan.csv` 是主补货计划, 每个 SKU 一行, 字段包括:

`sku`

`avg_daily_demand`

`reorder_point_units`

`recommended_order_qty`

`priority_band`

`expected_days_of_cover_after_order`

`replenishment_exceptions.json` 是高风险异常列表, 只列出需要补货且优先级是 `critical` 或 `high` 的 SKU。

它具体考察什么能力

1. 数据读取和表格处理能力

agent 要能读取多个 CSV, 并按 `sku` 把需求、库存、政策合并起来。

2. 业务公式理解能力

它需要正确计算:

$\text{avg_daily_demand} = \text{SKU 在所有日期上的平均每日需求}$

$\text{reorder_point_units} = \text{ceil}(\text{avg_daily_demand} * \text{lead_time_days} + \text{safety_stock_units})$

3. 补货数量计算能力

如果库存低于补货点, 就计算缺口, 并按包装规格向上取整, 同时满足最小起订量:

$\text{gap} = \text{reorder_point_units} - \text{on_hand_units}$

$\text{recommended_order_qty} = \text{向上取整到 order_pack_size, 并至少达到 minimum_order_qty}$

如果 $\text{gap} \leq 0$, 补货量就是 0。

4. 运营优先级判断能力

根据库存覆盖天数判断优先级:

$\text{current_days_of_cover} = \text{on_hand_units} / \text{avg_daily_demand}$

规则是:

```
critical = current_days_of_cover <= lead_time_days
high = current_days_of_cover <= high_priority_cover_days
monitor = otherwise
```

5. 输出格式控制能力

CSV 列顺序必须固定，JSON 结构也必须固定。这个任务不是“写分析报告”，而是生成机器可验证的运营文件。

6. 异常排序和规则解释能力

JSON 异常清单要：

- 只包含 recommended_order_qty > 0 且优先级为 critical 或 high 的 SKU
- 按 critical 优先于 high 排序
- 同优先级按 days_of_cover 升序
- 再按 sku 升序
- 每条异常要写出触发规则 trigger_rule

为什么这个任务适合 skill benchmark

这个任务很适合测试 supply-chain-manager 这类领域 skill 是否有帮助，因为它不是纯编程题，而是带有供应链/库存管理语义的确定性任务：

- agent 需要理解补货点、覆盖天数、安全库存、提前期、包装规格这些概念。
- 但最终答案又不是主观判断，可以用测试精确验证。
- no_skill 条件下，agent 只能靠任务说明完成。
- provided_skills 条件下，agent 可以借助 supply-chain-manager 里的库存和供应链方法。
- self_created_skills 条件下，可以观察 agent 是否能把补货逻辑总结成自己的可复用流程。

任务初测

Codex + Provided Skills

运行时间：2026-04-07T03:12:40Z

字段	值
任务	online-retail-replenishment-review
Agent	codex
模型	gpt-5.4
Skill 条件	provided_skills
Agent 返回码	0

测试状态	failed
测试结果	2 passed, 1 failed
总耗时	1026.151 sec

codex + No Skill

运行时间：2026-04-07T06:15:01Z

字段	值
任务	online-retail-replenishment-review
Agent	codex
模型	gpt-5.4
Skill 条件	no_skill
Agent 返回码	0
测试状态	failed
测试结果	2 passed, 1 failed
总耗时	155.45 sec

没拉开差距，无skill时，agent自行构造了python脚本完成，两次任务codex的错误一致，可能是prompt写的引起误导。

没拉开差距有可能是任务太简单，或者目前的codex+gpt4.5太强，换个试试看。

另外查看agent输出发现codex在两次任务中都没有使用到提供的skill，都是自行构造了python脚本完成，任务+skill设置不合理！

ps. 另外目前的prompt中提示说这是一次benchmark测试，这个后面要删除。==>已修正

Claude Code + Provided Skills

运行时间：2026-04-07T08:25:33Z

字段	值
----	---

任务	online-retail-replenishment-review
Agent	claude / Claude Code
模型	qwen3.5-plus
Skill 条件	provided_skills
Agent 返回码	0
测试状态	failed
测试结果	2 passed, 1 failed
总耗时	64.845 sec

还是没有拉开差距

Claude Code + No Skill

运行时间：2026-04-07T08:47:24Z

字段	值
任务	online-retail-replenishment-review
Agent	claude / Claude Code
模型	qwen3.5-plus
Skill 条件	no_skill
Agent 返回码	0
测试状态	failed
测试结果	2 passed, 1 failed
总耗时	91.951 sec

任务不行！需要重新构建！

任务二次设计

把当前所有任务情况整理成文档，包含任务内容（我非管理运营领域专业人士，这点可说的详细点，包含任务背景、任务具体内容等）、任务数据来源、任务输入输出、任务提供的skill、考察agent方向

下面是目前重新设计后的几个任务。整体思路是：把公开数据集和公开 skill 中的运营框架结合起来，要求 agent 输出可验证的运营决策。

1. smoke test: online-retail-replenishment-review

库存管理

这是一个**零售补货复盘任务**，目标是根据真实销售需求历史、当前库存和库存政策，生成一份标准化补货计划。

在零售或电商场景里，企业每天都要回答一个很现实的问题：

- 哪些商品快断货了？
- 是否应该补货？
- 补多少才合理？
- 哪些缺货风险更紧急？

这类问题通常属于库存管理或 replenishment（补货）工作。它既有业务含义，也有明确公式，因此很适合做 deterministic benchmark。

任务具体内容

agent 需要读取每个 SKU 的日需求、当前库存和补货政策，计算：

- 平均日需求
- 补货点
- 推荐订货量
- 优先级
- 补货后库存覆盖天数

此外还要把高风险补货异常单独输出成 JSON。

数据来源

主数据集：

- UCI Online Retail II
- 参考说明：[online-retail source.md](#)

数据处理方式：

- 从真实交易记录中抽取 SKU 日需求历史。
- 再补充本地冻结的库存与补货政策字段，使任务可重复评分。

输入

- daily_sku_demand.csv
- current_inventory.csv
- inventory_policy.csv

输出

- replenishment_plan.csv
- replenishment_exceptions.json

提供的 skill

- supply-chain-manager

这个 skill 主要覆盖：

- 供应链与库存管理基本概念
- 补货点、安全库存、服务水平等框架

主要考察 agent 的方向

- 表格读取和聚合
- 基础库存管理公式
- 补货优先级判断
- 严格输出结构

问题

这个任务虽然有真实外部数据来源，但在试跑里发现：

- 强模型即使不用 skill，也能靠说明和脚本稳定完成
- skill 条件没有带来明显区分

2. dataco-control-tower-exception-review

这是一个**供应链履约控制塔任务**，目标是从订单与运输表现中找出高风险订单、线路风险和应对动作。

业务背景

“控制塔（control tower）”是供应链里很常见的概念。你可以把它理解成一个运营监控中心，负责持续回答这些问题：

- 哪些订单有延迟风险？
- 哪些运输线路（lane）表现变差了？
- 哪些客户会受影响？
- 现在应该通知客户、切换运输方式，还是发起承运商复盘？

这类工作并不只是“算晚了几天”，而是要把数据指标转成可执行的运营动作。

任务具体内容

agent 需要完成 3 件事：

1. 对每笔订单做风险分级例如分成 `critical`、`high`、`monitor`
2. 给每笔订单分配 control-tower action 例如：
 - `mode_change`
 - `customer_notify`
 - `carrier_review`
 - `monitor`
3. 对线路层面输出风险登记与总览 summary 包括：
 - 哪些 lane 风险更大
 - 应用什么 mitigation
 - 整体 value at risk
 - action 分布

数据来源

主数据集：

- DataCo SMART Supply Chain
- 参考说明： [dataco source.md](#)
- provenance: [dataco provenance.md](#)

数据处理方式：

- 从原始订单和物流数据中构造订单快照
- 聚合出 lane scorecard
- 加入固定 customer commitment 与 control policy

输入

- `order_snapshot.csv`
- `carrier_lane_scorecard.csv`
- `customer_commitments.csv`
- `control_policy.json`

输出

- `control_tower_actions.csv`
- `lane_risk_register.json`
- `scorecard_summary.json`

提供的 skill

- **supply-chain-manager**
 - 功能：提供供应链整体视角，比如服务、成本、韧性等决策框架。
 - 对任务的帮助：帮助 agent 理解为什么某些订单和线路风险要优先按客户服务或供应链韧性来处理。
- **logistics-manager**
 - 功能：提供运输、承运商、线路表现、物流服务水平等物流管理知识。
 - 对任务的帮助：帮助 agent 理解 **otif_rate**、线路风险、承运商复盘、运输方式切换等动作为什么合理。
- **operations-manager**
 - 功能：提供 KPI、流程控制、owner 分配、异常升级等运营管理知识。
 - 对任务的帮助：帮助 agent 把识别出的风险整理成可执行的 action、owner 和 summary，而不是只停留在分类层面。

主要考察 agent 的方向

- 从订单和 lane 数据识别履约风险
- 把风险指标映射成具体 action
- 使用框架字段而不是只输出数值
- 进行 risk register 和 summary 汇总
- 保持结构化输出的精确性

相比简单补货任务，它更接近真实运营分析师或 control-tower analyst 的工作：

- 不是只算公式
- 而是要把“延迟、OTIF、客户价值、线路表现”转成运营动作

3. portland-sourcing-concentration-review

定位：采购与供应商管理方向

这是一个采购集中度与采购策略任务，目标是判断某个采购品类是否过度依赖头部供应商，并给出采购策略与风险登记。

业务背景

组织在采购时，不只是问“花了多少钱”，还要问：

- 某个品类是不是太依赖某一家供应商？
- 这类采购是高风险还是低风险？
- 应该继续合作、重新招标，还是建立第二供应源？

这类问题在采购管理、供应商管理、sourcing strategy 里非常核心。

任务里用到的一个重要概念是 **Kraljic Matrix**（克拉利奇矩阵）。它把采购品类分成 4 类：

- strategic
- leverage
- bottleneck
- non_critical

这个矩阵的核心思想是：

- 一边看“这类采购花多少钱、业务影响多大”
- 一边看“供应风险高不高、替代难不难”

不同象限对应不同采购策略。

任务具体内容

agent 需要完成 3 件事：

1. 计算每个采购品类的 spend 和头部供应商占比
2. 为每个品类判定 Kraljic 象限和 sourcing strategy
3. 识别 procurement anti-pattern，并生成风险登记与行动计划

这里的 anti-pattern 例如：

- single_sourcing
- price_only_focus
- supplier_fragmentation

数据来源

主数据集：

- Open Contracting Data Registry / City of Portland procurement publication
- 参考说明：[portland source.md](#)
- provenance：[portland provenance.md](#)

数据处理方式：

- 从 OCDS CSV 表中抽取 awards、supplier、item classification、buyer bureau
- 映射成固定的 benchmark category
- 冻结阈值与策略映射，便于自动评分

输入

- awards.csv
- supplier_profile.csv
- category_policy.json

输出

- kraljic_category_matrix.csv
- supplier_action_plan.csv
- procurement_risk_register.json

提供的 skill

- supply-chain-manager
 - 功能：提供采购策略、Kraljic 矩阵、供应商管理和采购 anti-pattern 等知识。
 - 对任务的帮助：帮助 agent 判断一个品类应该属于哪种采购象限，以及是否存在 single_sourcing、price_only_focus 等问题。
- operations-manager
 - 功能：提供运营执行、owner 分配、KPI 和后续跟进机制等知识。
 - 对任务的帮助：帮助 agent 把采购分析结果进一步转成行动计划、责任人和升级路径。

主要考察 agent 的方向

- spend aggregation
- top supplier concentration 分析
- Kraljic 分类
- anti-pattern 识别
- 将采购风险映射到 mitigation 和 follow-up
- 对字符串、枚举和 JSON 输出保持精确

这个任务比看起来更难，因为它不是简单财务汇总，而是要做“采购管理意义上的解释”：

- 同样是头部供应商占比高
- 有时意味着 single_sourcing
- 有时意味着 price_only_focus
- 有时又可能意味着类别本身是 bottleneck

这正是领域 skill 可能真正帮助 agent 的地方。

4. orlib-disruption-recovery-control

定位：制造运营、产能恢复和调度方向。

这是一个制造排程恢复任务，目标是在机器停机后，重新排出一份可行 schedule，并给出 bottleneck 报告和恢复动作。

业务背景

制造运营里有一个很常见的问题：

- 原计划已经排好了
- 结果某台机器突然停机
- 现在生产顺序要重排

- 同时还要判断哪些订单会延误、要不要加班、要不要通知客户

这类问题本质上是 job-shop scheduling（作业车间调度）里的 disruption recovery（中断恢复）。

它有两层难度：

1. 算法层新排程必须满足机器约束、工序先后顺序、停机窗口约束
2. 运营决策层哪台机器是瓶颈？哪些订单应升级？该采取 overtime、resequencing 还是 customer_escalation？

任务具体内容

agent 需要完成 4 件事：

1. 生成新的 recovery_schedule.csv
2. 计算 schedule_metrics.json
3. 输出 bottleneck_report.json
4. 给每个 job 输出 recovery_action_plan.csv

这里不仅要排程可行，还要输出管理语义：

- root_cause
- decision_hierarchy
- owner_function
- skill_framework

数据来源

主数据集：

- OR-Library Job Shop Scheduling
- 当前选用实例：ft06
- 参考说明：[orlib source.md](#)
- provenance：[orlib provenance.md](#)

数据处理方式：

- 从 OR-Library jobshop1.txt 解析 ft06
- 生成 baseline schedule
- 注入固定 downtime window
- 加入本地 due date、service criticality 和 recovery policy

输入

- jobshop_instance.csv
- baseline_schedule.csv
- machine_downtime.csv

- customer_priority.csv
- recovery_policy.json

输出

- recovery_schedule.csv
- schedule_metrics.json
- bottleneck_report.json
- recovery_action_plan.csv

提供的 skill

- **operations-manager**
 - 功能：提供瓶颈管理、约束思维、运营优先级和恢复控制等知识。
 - 对任务的帮助：帮助 agent 不只排出新 schedule，还能解释哪台机器是瓶颈、为什么要加班或升级客户沟通。
- **supply-chain-manager**
 - 功能：提供服务优先级、跨流程协同和供应链恢复视角。
 - 对任务的帮助：帮助 agent 理解为什么某些 job 要优先保护客户承诺，以及恢复动作背后的服务/成本权衡。

如果以后再导入 **capacity-planning** skill，这个任务在产能与瓶颈分析上会更完整。

主要考察 agent 的方向

- 排程可行性
- 约束满足
- downtime 避让
- makespan / tardiness 计算
- bottleneck 识别
- 恢复动作映射
- 保持管理枚举字段精确

这个任务很适合区分两类能力：

- 能不能排出一份“数学上可行”的 schedule
- 能不能把结果解释成“运营上可执行”的恢复方案

二次测试

本轮结论

- Codex
 - DataCo: provided 3/3, no_skill 3/3

- Portland: provided 3/3, no_skill 3/3
- OR-Library: provided agent 运行失败未产出文件, no_skill 2/3
- Claude Code qwen3.5-plus
 - DataCo: provided 3/3, no_skill 2/3
 - Portland: provided 0/3, no_skill 0/3
 - OR-Library: provided 2/3, no_skill 2/3

问题总结:

1. 不具备管理运营相关专业知识, 难以自行构造合适任务, 只能依靠LLM
2. 目前LLM构造的任务存在以下问题:
 - a. 没有做到“必须依赖领域skill才能显著提升表现”
 - b. 目前测试agent都倾向于写脚本而不是调用skill
 - c. instruction中给予的指导太详细, 强模型往往可以直接根据 instruction 和数据编写脚本完成任务
 - d. 任务难度不足, 拉不开差距
 - e. 任务专业程度难以判断
3. skill有没有被使用无法自动测出, 需要人工根据输出记录分析
4. agent自行构造skill完成任务

当前任务已经能测试结构化运营输出, 但还没有充分做到“必须依赖领域 skill 才能显著提升表现”, 因此 benchmark 仍需进一步减少 instruction 泄露、增强 skill 使用证据, 并补齐 self_created_skills 条件。

任务三次设计

结合二次测试的结果和王亚仙博士的修改意见, 对任务进行了三次设计:

1. 当前这几个任务本身确实是operations领域具有代表性的任务, 可继续使用
2. 针对instruction.md的问题, 进行了以下修改:
 - a. 保留 确定性的 规则
 - 输入输出 schema
 - 数值公式
 - 排序和硬阈值
 - b. 收回 instruction 中过于直接的高层管理映射
 - `owner\_function`
 - `decision\_hierarchy`
 - `reason\_code`
 - `anti\_pattern`
 - `follow\_up`
 - `root\_cause`
 - c. 让这些高层字段更多依赖 task-local skills 中已有的运营框架, 但仍要求输出值落在 policy 允许的 taxonomy 内

d. instruction只包含：

- 业务背景
- 要产出什么
- 输入文件和输出文件
- 字段含义
- 基本格式要求

测试结果：

Agent	Skill 条件	DataCo	Portland	OR-Library
Codex	provided_skills	failed 1/3	passed 3/3	passed 3/3
Codex	no_skill	failed 2/3	failed 1/3	passed 3/3
Claude Code	provided_skills	failed 1/3	failed 0/3	failed 1/3
Claude Code	no_skill	failed 2/3	failed 0/3	failed 2/3

经过仔细检查，发现这个版本skill设定混乱，instruction中竟然直接把skill情况写进去了，虽然没有直接暴露skill，但是给agent提供了skill名，导致输出结果中skill幻觉太多。

重新梳理instrction，删除skill相关表述。重跑：

Agent	Skill 条件	DataCo	Portland	OR-Library
Codex gpt-5.4	provided_skills	failed 2/3	passed 3/3	passed 3/3
Codex gpt-5.4	no_skill	failed 2/3	failed 1/3	failed 2/3
Claude Code qwen3.5-plus	provided_skills	failed 1/3	failed 0/3	failed 2/3
Claude Code qwen3.5-plus	no_skill	failed 2/3	failed 0/3	failed 2/3

本轮任务失败主要集中在：

- 枚举字段精确性
- 专业分类判断
- 数值字符串格式

- 自然语言解释替代固定分类体系

面向管理运营领域的 SkillBench 设计与可复现实验清单

数据集清单

T01 层级零售销量预测（多层聚合）

- 任务描述：给定历史销量/价格/促销等数据，输出未来28天SKU×店的点预测，采用固定切分与WRMSSE、MAPE等指标做自动评分
- 输入/输出格式：输入CSV/Parquet；输出提交CSV (id, d_1..d_28)
- 推荐数据集：M5竞赛数据，42840条层级时间序列，最低层需提交30490条预测，数据来自沃尔玛
- 数据许可：Kaggle竞赛规则标注学术、非商业使用，下载需接受规则，链接：<https://www.kaggle.com/c/m5-forecasting-accuracy/rules>
- 是否确定性：否（预测为统计性），可做口径固定的自动评分

~~T02 通用时间序列预测基准~~

- 任务描述：~~多领域单/多步序列预测，验证预测技能的通用性与可迁移性~~
- 输入/输出格式：~~输入.tsf/CSV；输出预测数组+评估JSON~~
- 推荐数据集：~~M4数据集，100000条时间序列，配套61种方法基准论文与数据~~
- 数据许可：~~开放研究数据，官网可下载，链接：<https://www.m4.unic.ac.cy/the-dataset/>~~
- 是否确定性：~~否~~

T03 电商订单履约SLA违约判定

- 任务描述：依据订单创建/出库/签收时间戳，按SLA规则输出违约订单列表与统计结果
- 输入/输出格式：输入SQL/CSV；输出JSON（违约清单+指标）
- 推荐数据集：Brazilian E-Commerce (Olist)，约10万条订单，包含订单状态、价格、运费、位置等多表数据
- 数据许可：Kaggle数据集（DOI: 10.34740/KAGGLE/DSV/195341），下载链接：<https://doi.org/10.34740/KAGGLE/DSV/195341>（需登录）
- 是否确定性：是

T04 客服响应SLA监测与报表

- 任务描述：计算首响时间、解决时间分布、SLA达成率，输出固定口径的日报/周报表
- 输入/输出格式：输入CSV；输出Markdown/HTML报表+JSON指标

- 推荐数据集：Customer Support on Twitter，超300万条品牌客服推文与回复，含响应时延相关字段
- 数据许可：Kaggle数据集，遵循平台条款，链接：
<https://www.kaggle.com/datasets/thoughtvector/customer-support-on-twitter>
- 是否确定性：是

T05 购物篮分析与补货优先级

- 任务描述：计算关联规则、复购率、Top-N热销商品，生成确定性补货优先级清单
- 输入/输出格式：输入CSV；输出JSON（规则/清单）
- 推荐数据集：Instacart 2017，超300万订单、20万用户，官方提供匿名化数据与字典
- 数据许可：官方下载，非商业用途，受条款约束，链接：<https://tech.instacart.com/3-million-instacart-orders-open-sourced-d40d29ead6f2>
- 是否确定性：是

T06 库存策略参数计算（EOQ）

- 任务描述：输入年需求、订货成本、持有成本，输出闭式解EOQ（经济订货批量）
- 输入/输出格式：输入JSON；输出JSON（EOQ、年订单次数等）
- 推荐数据集：采用公开公式与合成成本参数，基于Harris(1913)EOQ经典模型
- 数据许可：自建生成器（MIT许可），引用EOQ起源综述
- 是否确定性：是

T07 订货点（ROP）与安全库存

- 任务描述：输入日均需求、提前期、服务水平/安全库存规则，输出订货点ROP
- 输入/输出格式：输入JSON；输出JSON（ROP、SS安全库存）
- 推荐数据集：合成数据（需求/提前期分布由T01/T03派生），采用行业标准ROP计算公式
- 数据许可：自建生成器，引用行业公式说明
- 是否确定性：是

T08 生产/质检异常与缺陷判别

- 任务描述：通过传感器特征判定产品合格/不合格，输出关键特征报告，用固定模型/阈值自动评分
- 输入/输出格式：输入CSV；输出预测CSV+解释JSON
- 推荐数据集：UCI SECOM，1567个样本、590项传感器特征、二分类标签
- 数据许可：CC BY 4.0许可，链接：<https://archive.ics.uci.edu/ml/datasets/SECOM>
- 是否确定性：否（统计学习），评分结果确定

T09 设备预测性维护与工单排程

- 任务描述：预测设备剩余使用寿命（RUL）/故障风险，生成维护工单与排程（排程可设为确定性）
- 输入/输出格式：输入CSV；输出RUL预测+排程表
- 推荐数据集：NASA C-MAPSS，多变量时间序列，含训练/测试集，Zenodo可下载
- 数据许可：以Zenodo记录许可为准，链接：<https://zenodo.org/records/15346912>
- 是否确定性：混合（预测非确定、排程可设为确定）

T10 KPI时间序列在线异常检测

- 任务描述：对指标数据流输出异常点集合，固定阈值、算法与随机种子保证确定性
- 输入/输出格式：输入CSV（timestamp,value）；输出JSON（anomalies）
- 推荐数据集：NAB流式异常检测基准，官方GitHub可获取
- 数据许可：以仓库许可为准，链接：<https://github.com/numenta/NAB>
- 是否确定性：是（固定算法/阈值）

T11 互联网业务KPI异常检测（Yahoo S5）

- 任务描述：在标注数据上输出异常点，按固定协议评估F1值、延迟惩罚等指标
- 输入/输出格式：输入CSV；输出JSON
- 推荐数据集：Yahoo Webscope S5，367条真实/合成时间序列，含异常标注
- 数据许可：需注册，非商业研究条款，链接：
<https://webscope.sandbox.yahoo.com/catalog.php?datatype=s&did=70>
- 是否确定性：是（固定协议）

T12 AIOps KPI异常检测（竞赛版）

- 任务描述：在KPI数据流上检测异常，输出结果并评估F1、召回率等指标
- 输入/输出格式：输入CSV；输出JSON
- 推荐数据集：NetManAIOps KPI-Anomaly-Detection，公开仓库含数据
- 数据许可：MIT许可，链接：<https://github.com/NetManAIOps/KPI-Anomaly-Detection>
- 是否确定性：是（固定协议）

T13 工单流程挖掘与合规检查（XES/CSV）

- 任务描述：从事件日志计算流程吞吐、等待、返工等KPI，按规则输出违规案例列表
- 输入/输出格式：输入XES/CSV；输出JSON（violations,kpis）
- 推荐数据集：采用IEEE 1849标准XES事件日志格式，由流程挖掘IEEE工作组制定
- 数据许可：标准参考DOI：10.1109/IEEESTD.2016.7740858（或1849-2023最新版）
- 是否确定性：是

T14 ITSM Helpdesk工单流程预测（剩余时间/下一事件）

- 任务描述：基于事件日志预测工单剩余处理时间、下一活动，可同步做规则合规检查

- 输入/输出格式：输入XES；输出预测CSV+评估JSON
- 推荐数据集：Helpdesk Log（意大利公司），预测性过程监控常用基准
- 数据许可：4TU DOI链接：<https://doi.org/10.4121/uuid:0c60edf1-6f83-4e75-9367-4c63b3e9d5bb>
- 是否确定性：混合（预测非确定、合规确定）

T15 事件日志驱动的事故管理流程分析

- 任务描述：计算事故处理时长、SLA超时率、瓶颈活动，输出整改建议（仅指标计分）
- 输入/输出格式：输入XES；输出JSON指标
- 推荐数据集：BPI Challenge 2013 Incidents，事故管理事件日志基准
- 数据许可：通过BPI/4TU获取，需登录确认许可
- 是否确定性：是（指标计算）

T16 车辆路径规划（CVRP）

- 任务描述：输入客户坐标、需求、车辆容量，输出配送路线，按可行性+目标值确定性判卷
- 输入/输出格式：输入JSON/TSPLIB；输出路线JSON
- 推荐数据集：CVRPLIB，汇集经典CVRP测试实例
- 数据许可：以官网说明为准，链接：<http://vrp.atd-lab.inf.puc-rio.br/index.php/en/>
- 是否确定性：是（以目标值判定）

T17 带时间窗的车辆调度（VRPTW）

- 任务描述：输入时间窗、服务时长，输出路线与到达时间，判卷规则同CVRP
- 输入/输出格式：输入JSON；输出路线+时间表
- 推荐数据集：Solomon 1987 VRPTW实例，VRP-REP平台提供
- 数据许可：链接：<http://vrp.atd-lab.inf.puc-rio.br/index.php/en/>（Solomon集）
- 是否确定性：是（目标值）

T18 城市出行派单与需求高峰资源配置

- 任务描述：基于公开出行数据识别需求热区，生成车辆/司机配置方案（固定口径）
- 输入/输出格式：输入Parquet；输出JSON（allocation）
- 推荐数据集：NYC TLC trip record，纽约出租车官方开放行程数据
- 数据许可：官网与AWS Open Data均可获取，链接：<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>
- 是否确定性：混合（预测/规划）

T19 公共服务工单分派与响应时效分析

- 任务描述：按投诉类型、区域、机构统计工单积压与超时情况，输出分派建议清单

- 输入/输出格式：输入CSV；输出JSON指标+清单
- 推荐数据集：NYC 311，2010年至今公共服务工单数据，无个人识别信息
- 数据许可：链接：<https://data.cityofnewyork.us/Social-Services/311-Service-Requests-from-2020-to-Present/erm2-nwe9>
- 是否确定性：是（指标计算）

T20 航班延误与运行绩效KPI计算

- 任务描述：计算航班准点率、延误原因分布、航线瓶颈，可附加延误预测（预测非确定）
- 输入/输出格式：输入CSV；输出JSON KPI
- 推荐数据集：BTS Airline On-Time Performance，1987-2025年月度航班运行数据
- 数据许可：官网逐月下载，链接：<https://transtats.bts.gov/ontime/>
- 是否确定性：是（KPI计算）

Skills 清单

一、项目管理与任务流 (Project & Workflow Management)

pm-skills (项目管理专家套件)

- 所属领域：项目管理 / Atlassian 生态运营
- 来源：<https://skillsmp.com/skills/comeonoliver-skillshub-skills-alirezarezvani-claude-skills-project-management-skill-md>
- 详细介绍：由 Alireza Rezvani 开发的生产级套件。它不仅是一个工具，更是将项目管理角色分化为六个专业子技能：
 - **Senior PM**：专注于投资组合管理、风险分析和全局资源规划。
 - **Scrum Master**：提供速率预测（Velocity Forecasting）、Sprint 健康度检查及回顾会议引导。
 - **Jira/Confluence Expert**：通过 JQL 查询自动化任务流，管理知识库架构。
 - **Atlassian Admin**：处理复杂的权限管理与集成配置。

该技能通过 MCP 协议实现与 Jira 和 Confluence 的实时联动，并内置了 `velocity_analyzer.py` 等脚本进行数据分析。

Project Management Specialist (通用项目管理专家)

- 所属领域：通用管理
- 来源：<https://skillsmp.com/skills/selfdriven-octo-skillzeb-skills-intelligence-organic-human-human-project-management-specialist-skill-md>
- 详细介绍：这是一个独立于特定工具的管理方法论技能包。它定义了智能体在管理复杂项目时必须遵循的“专家协议”，核心能力包括：

- **规划与组织**：定义项目范围、目标、WBS 拆解及资源计划。
- **交付治理**：监控任务依赖关系，并根据环境变化动态调整交付策略。
- **风险与议题管理**：系统化识别潜在阻碍，制定缓解计划并执行升级流程。
- **利益相关者沟通**：管理预期，通过沟通矩阵确保跨角色协作的透明度。

Writing Plans / Superpowers (实施计划编写)

- **所属领域**：研发管理 / 计划运营
- **来源**：(<https://www.google.com/search?q=https://skills.sh/obra/superpowers/writing-plans>)
- **详细介绍**：该技能将管理中的“规划”职能发挥到极致，特别适用于复杂的软件研发任务。它强制智能体遵循 TDD（测试驱动开发）逻辑，将大需求拆解为 2-5 分钟内可完成且可验证的原子任务。它要求智能体在动工前先绘制文件结构图，明确各模块边界，确保即使是零背景的执行者也能根据该计划产生高质量结果。

MCP 虾任务管理器 (Shrimp Task Manager)

- **所属领域**：编程 workflow 管理
- **来源**：(<https://modelscope.cn/mcp/servers/@cjo4m06/mcp-shrimp-task-manager>)
- **详细介绍**：基于 MCP 协议的智能任务系统，专为解决 Agent 在复杂编程任务中“容易遗忘”和“重复劳动”的问题设计。它具备任务复杂度自动评估功能，并能自动更新任务摘要以优化内存性能。其核心优势在于“任务记忆”，能参考过去成功的解决方案来处理当前问题，并通过思维链（CoT）逻辑引导 Agent 进行系统化推理。

Todo Management 1.1.2 (本地待办治理)

- **所属领域**：任务管理
- **来源**：[ClawHub](#)
- **详细介绍**：一个极简且安全的本地管理工具。它通过 SQLite 数据库在每个工作区内独立运行。支持任务状态跟踪（待处理、进行中、已完成、已跳过）以及任务分组管理。该技能严格限制智能体不得随意写文件，所有变更仅限于数据库，确保了管理过程中的数据一致性和系统整洁。

二、供应链与零售运营 (Supply Chain & Retail Operations)

inventory-demand-planning (需求预测与库存规划)

- **所属领域**：供应链管理 / 零售业
- **核心作用**：提供 SKU 需求预测、安全库存计算及补货规划。

- 来源: (<https://github.com/affaan-m/everything-claude-code>)
- 详细介绍: 这是一款专注于多门店零售场景的高级技能。它能使智能体变身为资深需求计划员, 管理 300-800 个 SKU。核心功能包括:
 - 预测模型: 支持指数平滑法 (Exponential Smoothing) 和 STL 分解等复杂统计模型。
 - SKU 分类: 自动执行 ABC/XYZ 分类法, 帮助管理人员识别高价值和高波动性的商品, 实现优先级排序。
 - 动态补货: 根据服务水平目标 (Service Level) 和交货期波动 (Lead-time Volatility) 动态计算安全库存。此外, 它还能评估促销活动对销量的提升及后续的“需求回落”效应。

supply-chain-manager (全链条供应链管理)

- 所属领域: 制造业供应链
- 核心作用: 覆盖采购、物流、库存及供应商关系的综合治理。
- 来源: (<https://github.com/theneoai/awesome-skills>)
- 详细介绍: 该技能将制造业的供应链职能系统化。它聚焦于 S&OP (销售与运营规划) 流程、产能规划及物流网络优化。通过该技能, 智能体可以协助管理人员进行供应商多元化评估, 建立应对政治不稳定或经济波动风险的韧性框架。其不仅关注短期成本压降, 更侧重于建立长期的、可持续的供应网络设计。

procurement-review (采购审计与供应商协同)

- 所属领域: 采购运营 / 合规
- 核心作用: 审查采购到付款流程, 评估供应商绩效与合规风险。
- 来源: (<https://github.com/tinh2/skills-hub-registry>)
- 详细介绍: 这是一个深度分析型技能, 涵盖了从 MRP (物料需求计划) 逻辑评估到 BOM 准确性审计的各个环节。核心分析维度包括:
 - 供应商评分: 基于质量、时效、成本、安全 (Q/T/C/S) 四大框架构建计分卡。
 - 合规与风险: 识别供应商集中度风险, 验证保险及多样性合规。
 - SLA 监控: 自动追踪供应商的响应时效、首检合格率以及违约金的应用情况。

supply-chain-automation (供应链自动化设计)

- 所属领域: 业务自动化 / RPA
- 核心作用: 识别供应链流程中的自动化机会, 并设计 RPA 触发机制。
- 来源: (<https://github.com/kishorkukreja/awesome-supply-chain>)
- 详细介绍: 该技能通过关键词触发, 旨在帮助企业识别那些重复、低效的人工环节。它支持自动补货流程的逻辑设计, 并能将区块链追踪、物联网 (IoT) 数据集成到自动化工作流程中, 从而提升供应链的透明度和实时响应能力。

retail-operations-manager (零售门店运营管理)

- 所属领域: 零售运营

- **核心作用：**优化店铺日常运营、全渠道执行及损失防控（LP）。
- **来源：**(<https://github.com/theneoai/awesome-skills>)
- **详细介绍：**专注于零售实务的管理技能。它包含了库存控制、销售数据分析以及多门店一致性管理。它能协助经理执行视觉陈列（Visual Merchandising）标准，并为全渠道零售（如网订店取）提供物流和客户服务策略建议。

logistics-manager (物流与仓储管理)

- **所属领域：**物流运营
- **核心作用：**提供智能物流优化、仓储 3PL（第三方物流）管理及最后公里交付指导。
- **来源：**(<https://skillsmp.com/occupations/logisticians-and-project-management-specialists>)
- **详细介绍：**作为一个指导性技能，它侧重于物流策略的制定。包括路径规划优化、车队管理策略、仓库布局设计以及第三方物流服务商的绩效评估。

三、技术运维与基础设施 (Technical Ops & Infrastructure)

AWS Cost Operations (云成本运营)

- **所属领域：**财务运营 (FinOps)
- **来源：**(<https://skillsdirectory.com/skills/microck-aws-cost-operations>)
- **详细介绍：**这是目前 FinOps 领域最完整的技能之一，集成了 8 个 MCP 服务器。它不仅通过 Billing MCP 监控实时账单和预算利用率，还能调用 Pricing MCP 进行部署前的成本预测。其强大的功能在于“行动化”：智能体可以识别未使用的 S3 存储桶、过期的快照或过量拨备的实例，并主动生成优化建议或执行清理。

Terraform State Manager (基础设施状态管理)

- **所属领域：**基础设施管理 (IaC)
- **来源：**(<https://www.skillsdirectory.com/skills/armanzeroeight-terraform-state-manager>)
- **详细介绍：**专注于 Terraform 状态文件的安全运营。它为智能体设定了极其严苛的操作准则：任何涉及资源移动、导入或删除的操作，必须遵循“先备份状态、后执行变更、再运行 Plan 验证”的三步走流程。它主要用于解决状态冲突、重构资源地址以及在不同后端（如 S3 到本地）之间迁移基础设施。

Microsoft Foundry (智能体全生命周期管理)

- **所属领域：**AI 运维 (AI Ops)
- **来源：**(<https://skills.sh/microsoft/azure-skills/microsoft-foundry>)
- **详细介绍：**该技能管理的是“智能体”本身。它涵盖了从创建、容器化打包、推送到 ACR 镜像库，到托管部署、调用、批量评估及 Prompt 优化的全过程。它具备特殊的“追踪分析 (Trace Analysis)”能力，能诊断生产环境中的延迟和失败，从而实现对 AI 原生应用的持续治理。

Environment Manager (环境与配置治理)

- 所属领域：配置管理
- 来源：(<https://skillsdirectory.com/skills/glincker-environment-manager>)
- 详细介绍：负责在不同环境（开发、测试、生产）之间安全地管理变量和密钥。它支持 `.env` 文件自动化创建、AWS Secrets Manager 集成，以及 Docker/K8s 的配置校验。它能确保团队成员之间的配置同步，并自动生成环境变量文档，避免了传统管理中由于配置缺失导致的系统崩溃。

Filesystem Management (文件系统治理)

- 所属领域：系统运营
- 来源：<https://clawhub.ai/gtrusler/clawdbot-filesystem>
- 详细介绍：赋予智能体精确管理数字资产的能力。包括但不限于：递归遍历大规模目录、使用正则表达式进行全文内容搜索、批量文件操作。为了保证安全，它内置了路径校验以防止路径穿越攻击，并提供“干跑模式（Dry Run）”让管理员在执行删除等破坏性任务前进行预览。

四、业务与行业垂直运营 (Business & Vertical Operations)

Property-VAS (物业增值服务管理)

- 所属领域：社区治理 / 供应链运营
- 来源：(<https://skillhub.tencent.com/skills/property-vas>)
- 详细介绍：深度融合了业务管理实务的技能。它基于梁宁的 VCP 理论，为物业多种经营提供全套方案：
 - 供应商管理：提供包含资质、服务标准、售后响应在内的检查清单，并内置纯佣金、月结 30 天等谈判策略建议。
 - 私域运营：定义了“我是谁-服务谁-提供什么价值”的三步定位法，指导管理人员进行社群转化和发售预热。

Automation Workflows (自动化流设计)

- 所属领域：业务自动化
- 来源：<https://clawhub.ai/jk-0001/automation-workflows>
- 详细介绍：专门用于识别和优化那些高频重复的业务流程。它能指导智能体在复杂的跨工具环境（如 Zapier, Make, n8n）中建立触发与响应机制。该技能不仅涉及工具的使用，更强调对“自动化机会”的财务和时间成本评估，通过减少人工干预来提升整体运营杠杆。

五、策略优化与流程挖掘 (Strategy & Process Optimization)

Efficiency Booster (高效率做事逻辑思考法)

- 所属领域：效率治理 / 管理思维
- 来源：(<https://skillhub.tencent.com/skills/efficiency-booster>)
- 详细介绍：这是一个偏重“道”与“法”的管理技能。它不操作具体的软件，而是为智能体植入了一套***“目标-路径-资源-复盘”***的四步闭环框架。它要求智能体在接到任务时，首先使用 5W1H 法界定问题价值，然后定义三档完成标准（最低/优秀/卓越），最后通过里程碑规划和复盘机制确保系统性迭代。输出产物通常为结构化的执行手册。

Context Engineering Collection (上下文工程与运营卓越)

- 所属领域：运营优化 (Operational Excellence)
- 来源：(<https://www.skillsdirectory.com/skills/muratcankoylan-context-engineering-collection>)
- 详细介绍：针对 AI 运营中的成本与稳定性进行优化。通过压实（Compaction）技术总结冗长对话，以及观察掩蔽（Observation Masking）技术过滤无效工具输出。这种技能对于长周期的项目管理至关重要，它能显著提高信息增益，确保 Agent 在处理长达数周的项目流时不会因为 Token 过载而失去控制力。

PPTX Skill (沟通与报告管理)

- 所属领域：沟通管理
- 来源：(<https://skills.sh/anthropics/skills/pptx>)
- 详细介绍：管理运营中的重要环节是“汇报”。该技能提供从内容提取到幻灯片生成的完整流。它内置了 10 套精心设计的配色方案和布局模式，强制执行视觉 QA（质量保证）流程，自动检查文本溢出、低对比度或元素重叠，确保管理报告的专业性和品牌一致性。

Sinch Webhook Manager (Webhook 声明周期管理)

- 所属领域：API 运营
- 来源：(<https://www.skillsdirectory.com/skills/sinch-manage-webhook>)
- 详细介绍：专注于实时通讯接口的运营维护。它涵盖了 Webhook 的全生命周期，包括创建、参数更新、触发器配置及回调详情监控。当企业需要管理多路并发的实时通知流时，该技能能确保配置的正确性并快速报告异常报错。

Property-VAS (物业增值服务管理)

- 所属领域：行业垂直运营
- 核心作用：基于供应链协同理论，管理社区物业的供应商、私域运营及财务模型。
- 来源：(<https://skillhub.tencent.com/skills/property-vas>)

- **详细介绍：**这是一个高度细分实务的技能，深度整合了 VCP 顶层设计理论。它为管理者提供了一套完整的“供应商引入检查清单”，并明确了“纯佣金模式、月结 30 天、损耗分摊”等具体的商务谈判准则。